



Modelos predictivos en R para cancelaciones hoteleras

Modelo GLM y estrategias de overbooking para asegurar los ingresos

27 Marzo 2026

Anaís Nájar Martínez
Alberto López Alfaro
Gabriel Ferrández García

Grupo 11

Resumen Ejecutivo

- ❖ El hotel se enfrenta a **una tasa de cancelación crítica** del 33%, lo que desestabiliza la planificación y los ingresos.
- ❖ Desarrollamos un **modelo con Regresión logística binomial** para predecir qué reservas tienen un riesgo real de ser canceladas. Partiendo de un modelo simple, lo mejoramos hasta en dos ocasiones explicando como cambia.
- ❖ Tras obtener el modelo final, **comprobamos con ANOVA** la influencia de las variables, siendo estas todas significativas.
- ❖ **Riesgo:** El canal online presenta gran inestabilidad. La combinación de reservas caras con mucha antelación dispara el riesgo de cancelación.
- ❖ **Retención:** Ser cliente repetidor o realizar peticiones especiales reducen el abandono considerablemente.
- ❖ Implementación de una estrategia de **overbooking inteligente**. Ajustamos el umbral predictivo al 70% para proteger la reputación del hotel, utilizando el volumen de error estadístico para revender habitaciones de forma segura.

Agenda

1. Variable objetivo: Predicción de cancelaciones.
2. Primer modelo: Variables base.
3. Segundo modelo: Interacciones.
4. Tercer modelo: Términos cuadráticos.
5. Interpretación del modelo.
6. Comprobación de la significancia de las variables con ANOVA.
7. Estrategia de overbooking.
8. Conclusiones.
9. Próximos pasos.


Variable objetivo: Predicción de cancelaciones

Definición: Variable binaria (0= No cancela, 1= cancela).

Punto de partida: El hotel se enfrenta a una tasa de cancelación global crítica del 33%.

Objetivo: Desarrollar un modelo de Regresión Logística (GLM Binomial) para anticipar estas cancelaciones y proteger los ingresos del hotel.

El **EDA** que realizamos anteriormente reflejó que variables como la antelación, el precio y el canal de reserva influían en la tasa de cancelación.



Primer modelo: Variables base

```
Call:
glm(formula = cancelacion ~ market_segment_type + no_of_special_requests +
    avg_price_per_room + arrival_month + repeated_guest + lead_time +
    required_car_parking_space + no_of_weekend_nights, family = binomial(link = "logit"),
    data = datos_limpios)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.8233278	0.2277975	-25.564	< 2e-16 ***
market_segment_typeOffline	-0.8450985	0.0894598	-9.447	< 2e-16 ***
market_segment_typeOnline	1.0641294	0.0854336	12.456	< 2e-16 ***
no_of_special_requests	-1.5003948	0.0252411	-59.442	< 2e-16 ***
avg_price_per_room	0.0166682	0.0005089	32.751	< 2e-16 ***
arrival_month2	2.7612642	0.2185704	12.633	< 2e-16 ***
arrival_month3	2.4963136	0.2160038	11.557	< 2e-16 ***
arrival_month4	2.2573317	0.2150125	10.499	< 2e-16 ***
arrival_month5	1.8840721	0.2165223	8.702	< 2e-16 ***
arrival_month6	2.1692154	0.2151326	10.083	< 2e-16 ***
arrival_month7	2.0314497	0.2158748	9.410	< 2e-16 ***
arrival_month8	1.9766519	0.2151293	9.188	< 2e-16 ***
arrival_month9	1.8392012	0.2150181	8.554	< 2e-16 ***
arrival_month10	2.0903063	0.2139047	9.772	< 2e-16 ***
arrival_month11	2.5111755	0.2163654	11.606	< 2e-16 ***
arrival_month12	0.6035475	0.2218920	2.720	0.00653 **
repeated_guest	-1.7744356	0.3222670	-5.506	3.67e-08 ***
lead_time	0.0165369	0.0002222	74.411	< 2e-16 ***
required_car_parking_space	-1.5857087	0.1165665	-13.603	< 2e-16 ***
no_of_weekend_nights	0.1386608	0.0166838	8.311	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 45422 on 35758 degrees of freedom
Residual deviance: 30031 on 35739 degrees of freedom
AIC: 30071

- Hemos añadido las variables estudiadas en el EDA junto a variables estratégicas adicionales.
- **Todas las variables estudiadas son significativas**, pues sus p-valores son muy pequeños.
- **Mejora frente al modelo nulo (Deviance):**
 - Deviance nula (sin variables): 45.422
 - Deviance Residual (modelo 1): 30.031
- **AIC: 30.071**
- **R²: 0.3388**

Segundo modelo: Interacciones

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -4.880e+00  2.295e-01 -21.261 < 2e-16 ***
market_segment_typeOffline -7.685e-01  8.884e-02 -8.650 < 2e-16 ***
market_segment_typeOnline  1.160e+00  8.501e-02  13.644 < 2e-16 ***
no_of_special_requests   -1.586e+00  2.645e-02 -59.953 < 2e-16 ***
avg_price_per_room      5.904e-03  6.632e-04   8.902 < 2e-16 ***
arrival_month2          2.783e+00  2.183e-01  12.752 < 2e-16 ***
arrival_month3          2.585e+00  2.159e-01  11.974 < 2e-16 ***
arrival_month4          2.407e+00  2.150e-01  11.198 < 2e-16 ***
arrival_month5          2.026e+00  2.166e-01   9.353 < 2e-16 ***
arrival_month6          2.212e+00  2.154e-01  10.273 < 2e-16 ***
arrival_month7          2.108e+00  2.161e-01   9.752 < 2e-16 ***
arrival_month8          2.059e+00  2.153e-01   9.563 < 2e-16 ***
arrival_month9          1.971e+00  2.152e-01   9.159 < 2e-16 ***
arrival_month10         2.231e+00  2.140e-01  10.429 < 2e-16 ***
arrival_month11         2.657e+00  2.161e-01  12.297 < 2e-16 ***
arrival_month12         8.441e-01  2.216e-01   3.809  0.00014 ***
repeated_guest        -3.235e+00  5.997e-01 -5.395  6.87e-08 ***
lead_time           5.082e-05  6.859e-04   0.074  0.94094
required_car_parking_space -1.790e+00  1.248e-01 -14.350 < 2e-16 ***
no_of_weekend_nights    1.466e-01  1.687e-02   8.691 < 2e-16 ***
avg_price_per_room:lead_time 1.688e-04  6.880e-06  24.528 < 2e-16 ***
repeated_guest:lead_time  2.302e-02  5.173e-03   4.451  8.56e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

(Dispersion parameter for binomial family taken to be 1)

```
Null deviance: 45422 on 35758 degrees of freedom
Residual deviance: 29353 on 35737 degrees of freedom
AIC: 29397
```

- El impacto del precio y la fiabilidad del cliente repetidor cambia drásticamente dependiendo de la antelación de la reserva.
- **Interacción de las variables:**
 - Antelación x Precio de la habitación
 - Antelación x Cliente repetidor
- Las interacciones son **altamente significativas**.
- **AIC:** 29.397, reducción de casi 700 unidades frente al primer modelo.
- **R²:** 0.35

Tercer modelo: Términos cuadráticos

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)   -5.176e+00  2.532e-01 -20.444 < 2e-16 ***
market_segment_typeOffline -7.834e-01  8.938e-02 -8.764 < 2e-16 ***
market_segment_typeOnline  1.140e+00  8.568e-02 13.311 < 2e-16 ***
no_of_special_requests   -1.588e+00  2.649e-02 -59.949 < 2e-16 ***
avg_price_per_room      1.070e-02  1.961e-03  5.458 4.83e-08 ***
arrival_month2          2.786e+00  2.184e-01 12.755 < 2e-16 ***
arrival_month3          2.565e+00  2.161e-01 11.870 < 2e-16 ***
arrival_month4          2.366e+00  2.155e-01 10.979 < 2e-16 ***
arrival_month5          1.981e+00  2.172e-01  9.121 < 2e-16 ***
arrival_month6          2.167e+00  2.159e-01 10.037 < 2e-16 ***
arrival_month7          2.064e+00  2.167e-01  9.525 < 2e-16 ***
arrival_month8          2.021e+00  2.158e-01  9.366 < 2e-16 ***
arrival_month9          1.943e+00  2.155e-01  9.019 < 2e-16 ***
arrival_month10         2.196e+00  2.144e-01 10.246 < 2e-16 ***
arrival_month11         2.640e+00  2.163e-01 12.204 < 2e-16 ***
arrival_month12         8.262e-01  2.218e-01  3.725 0.000195 ***
repeated_guest         -3.199e+00  6.022e-01 -5.312 1.08e-07 ***
lead_time            2.165e-03  1.067e-03  2.029 0.042438 *
required_car_parking_space -1.786e+00  1.245e-01 -14.344 < 2e-16 ***
no_of_weekend_nights    1.440e-01  1.696e-02  8.491 < 2e-16 ***
I(lead_time^2)        -4.105e-06  1.960e-06  -2.095 0.036205 *
I(avg_price_per_room^2) -1.636e-05  6.676e-06  -2.450 0.014281 *
avg_price_per_room:lead_time 1.587e-04  7.609e-06 20.853 < 2e-16 ***
repeated_guest:lead_time  2.271e-02  5.180e-03  4.384 1.16e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for binomial family taken to be 1)
```

```
Null deviance: 45422 on 35758 degrees of freedom
Residual deviance: 29343 on 35735 degrees of freedom
AIC: 29391
```

- Incorporación del efecto cuadrático al tiempo de antelación y al precio.
- Reducción del **AIC marginal**. (6 unidades)
- El riesgo de cancelación aumenta con la antelación y con el precio, pero se estabiliza a partir de cierto límite temporal.
- Adoptamos este modelo como **modelo final**.
- Tenemos una **mejora del 35.4%** de este modelo respecto al modelo nulo.

Interpretación del modelo




Comprobación de la significancia de las variables con ANOVA

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			35758	45422	
market_segment_type	2	709.0	35756	44713	< 2.2e-16 ***
no_of_special_requests	1	4032.9	35755	40680	< 2.2e-16 ***
avg_price_per_room	1	674.2	35754	40006	< 2.2e-16 ***
arrival_month	11	1404.9	35743	38601	< 2.2e-16 ***
repeated_guest	1	136.7	35742	38465	< 2.2e-16 ***
lead_time	1	8129.1	35741	30336	< 2.2e-16 ***
required_car_parking_space	1	235.1	35740	30101	< 2.2e-16 ***
no_of_weekend_nights	1	69.1	35739	30031	< 2.2e-16 ***
I(lead_time^2)	1	92.5	35738	29939	< 2.2e-16 ***
I(avg_price_per_room^2)	1	109.4	35737	29830	< 2.2e-16 ***
avg_price_per_room:lead_time	1	463.6	35736	29366	< 2.2e-16 ***
repeated_guest:lead_time	1	22.5	35735	29343	2.061e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1					

- Confirmamos estadísticamente que **todas las variables** introducidas en el modelo final **aportan valor real**.
- Afirmamos que tanto las interacciones como los efectos cuadráticos son significativos.

Estrategia de overbooking



- Problema 50%: Genera **demasiados falsos positivos**. (2476)
- Solución 70%: **Reducimos** drásticamente los **falsos positivos**, los más peligrosos para los beneficios del hotel.
- Overbooking medio del 16.4%

Predicción		
Real	0	1
0	22932	979
1	6827	5021

Fiabilidad global con
el umbral al 70%:
78.17%

Conclusiones

Hemos desarrollado un **modelo capaz de adaptarse** al comportamiento real del cliente.

Ajustamos el umbral de decisión al 70% para **minimizar los falsos positivos**, priorizando en todo momento la reputación y el servicio del hotel.

Estrategias de overbooking: Compensamos esta precaución utilizando nuestra estimación de falsos negativos. Esto nos permite calcular estadísticamente cuántas habitaciones extra podemos vender de forma segura para maximizar la ocupación.

Aplicar políticas de reserva más controladas en el Canal Online.

Crear campañas dinámicas basadas en el nivel de riesgo. Mandar un cuestionario de personalización a aquellas reservas que veamos en riesgo.

Próximos pasos



Incluir nuevas variables de estudio para poder predecir mejor la tasa de cancelación de los clientes.



Crear otros modelos con nuevas herramientas para intentar hacer mejores predicciones y obtener mayor rendimiento.

Preguntas y sugerencias

Gracias por su atención

Back-up: Modelo 0 con step

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-9.882e+02	1.081e+02	-9.142	< 2e-16 ***
no_of_adults	1.273e-01	3.260e-02	3.904	9.44e-05 ***
no_of_children	1.961e-01	5.163e-02	3.798	0.000146 ***
no_of_weekend_nights	1.383e-01	1.711e-02	8.079	6.51e-16 ***
no_of_week_nights	4.814e-02	1.069e-02	4.501	6.77e-06 ***
type_of_meal_planMeal Plan 2	2.046e-01	5.758e-02	3.554	0.000379 ***
type_of_meal_planMeal Plan 3	1.050e+01	7.246e+01	0.145	0.884767
type_of_meal_planNot Selected	2.389e-01	4.529e-02	5.276	1.32e-07 ***
required_car_parking_space	-1.559e+00	1.168e-01	-13.353	< 2e-16 ***
room_type_reservedRoom_Type 2	-3.594e-01	1.144e-01	-3.142	0.001679 **
room_type_reservedRoom_Type 3	-3.103e-01	1.235e+00	-0.251	0.801527
room_type_reservedRoom_Type 4	-2.574e-01	4.537e-02	-5.673	1.40e-08 ***
room_type_reservedRoom_Type 5	-8.258e-01	1.752e-01	-4.714	2.43e-06 ***
room_type_reservedRoom_Type 6	-9.231e-01	1.293e-01	-7.142	9.22e-13 ***
room_type_reservedRoom_Type 7	-1.439e+00	2.678e-01	-5.375	7.67e-08 ***
lead_time	1.599e-02	2.408e-04	66.409	< 2e-16 ***
arrival_year	4.866e-01	5.357e-02	9.084	< 2e-16 ***
arrival_month2	2.808e+00	2.201e-01	12.755	< 2e-16 ***
arrival_month3	2.505e+00	2.178e-01	11.500	< 2e-16 ***
arrival_month4	2.309e+00	2.168e-01	10.647	< 2e-16 ***
arrival_month5	1.931e+00	2.189e-01	8.823	< 2e-16 ***
arrival_month6	2.200e+00	2.176e-01	10.111	< 2e-16 ***
arrival_month7	2.110e+00	2.185e-01	9.657	< 2e-16 ***
arrival_month8	2.083e+00	2.182e-01	9.546	< 2e-16 ***
arrival_month9	2.011e+00	2.190e-01	9.184	< 2e-16 ***
arrival_month10	2.316e+00	2.176e-01	10.645	< 2e-16 ***
arrival_month11	2.625e+00	2.189e-01	11.993	< 2e-16 ***
arrival_month12	7.211e-01	2.246e-01	3.211	0.001324 **
arrival_date	4.228e-03	1.671e-03	2.531	0.011387 *
market_segment_typeOffline	-9.820e-01	9.179e-02	-10.698	< 2e-16 ***
market_segment_typeOnline	8.501e-01	8.882e-02	9.572	< 2e-16 ***
repeated_guest	-2.164e+00	4.721e-01	-4.584	4.55e-06 ***
no_of_previous_cancellations	3.288e-01	9.045e-02	3.635	0.000278 ***
no_of_previous_bookings_not_canceled	-9.520e-02	7.775e-02	-1.224	0.220787
avg_price_per_room	1.819e-02	6.973e-04	26.084	< 2e-16 ***
no_of_special_requests	-1.534e+00	2.588e-02	-59.296	< 2e-16 ***

- **Intento inicial:** Introducción de todas las variables disponibles mediante el método step
- **Por qué lo descartamos:**
 - Ruido: Variables como el día exacto de llegada o el año no son útiles para crear conclusiones.
 - Categorías residuales: Tipos de habitación o planes de comida con subniveles no significativos no aportan valor real de clasificación.
 - Eficiencia: Nuestro modelo 1 logra un rendimiento casi idéntico utilizando un tercio de las variables, facilitando la interpretación comercial

Null deviance: 45422 on 35758 degrees of freedom
Residual deviance: 29716 on 35723 degrees of freedom
AIC: 29788