



# Modelos predictivos en cancelaciones hoteleras

Modelos de Machine Learning y aplicaciones de negocio.

14 Mayo 2026

Anaís Nájar Martínez  
Alberto López Alfaro  
Gabriel Ferrández García

Grupo 11

# RESUMEN EJECUTIVO

- ❖ **Limpieza de datos** irreales que formaban parte de nuestro dataset y **ordenación de los datos** ya que estamos ante una serie temporal. Partición de los datos en **train, validación y test**.
- ❖ Analizamos los datos y entrenamos diferentes modelos predictivos como XGBoost, LightGBM y Random Forest. **LightGBM** ha demostrado ser el más estable y el que mejor aprende frente a los otros modelos basándonos en la **precisión**.
- ❖ Hacemos un **análisis de las variables más influyentes de nuestro modelo final**. Observando como destacan las variables: tiempo de antelación de la reserva, número de peticiones especiales que nuestros clientes hacen y el mes de llegada. Además, mostramos el comportamiento de cada una de ellas de forma particular.
- ❖ Diferenciamos **dos perfiles muy claros**: el cliente que casi seguro cancelará y el cliente que es fiable.
- ❖ Implementación de una estrategia de **overbooking inteligente**. Ajustamos el umbral predictivo al 70% para proteger la reputación del hotel, utilizando el volumen de error estadístico para revender habitaciones de forma segura.

# AGENDA

1. Preparación de los datos
2. Metodología
3. Comparativa y selección de modelos
4. Modelo elegido
5. Análisis de variables
6. Creación de perfiles fiable vs riesgo
7. Estrategia de overbooking
8. Conclusiones
9. Próximos pasos


# PREPARACIÓN DE LOS DATOS PARA MEJORAR LA CAPACIDAD PREDICTIVA



ELIMINACIÓN DE FILAS CON VALORES IRREALES.



CREACIÓN DE LA VARIABLE BINARIA "TARGET".



TRANSFORMACIÓN DE VARIABLES CATEGÓRICAS MEDIANTE K-1 ENCODING.



DIVISIÓN TEMPORAL SIGUIENDO EL ORDEN CRONOLÓGICO DE LAS RESERVAS.

# ENTRENAMOS Y VALIDAMOS MODELOS PARA GARANTIZAR PRECISIÓN



Creación de modelos Random Forest, XGBoost y LightGBM .

Precisión como métrica de clasificación para la elección del modelo.

# COMPARATIVA Y SELECCIÓN DE MODELOS PRIORIZANDO ESTABILIDAD FRENTE A PRECISIÓN TEÓRICA

| MODELO     | XGBoost | Random Forest | LightGBM |
|------------|---------|---------------|----------|
| TRAIN      | 0.7397  | 0.6875        | 0.7877   |
| VALIDACIÓN | 0.8040  | 0.8501        | 0.8381   |
| TEST       | 0.8216  | 0.8545        | 0.8401   |

- **XGBoost:** Conseguimos un buen modelo haciendo uso del early stopping, pero obtiene el peor resultado.
- **Random Forest:** Alcanza la máxima precisión teórica, pero resulta ser un modelo demasiado inestable ante los cambios de temporada.
- **LightGBM:** Modelo seleccionado. Es el más equilibrado y con el que conseguimos la mayor estabilidad entre Train y Test.


# MODELO ELEGIDO CON MEJOR CAPACIDAD DE GENERALIZACIÓN

## LightGBM

|           | TRAIN  | VALIDACIÓN | TEST   |
|-----------|--------|------------|--------|
| PRECISIÓN | 0.7877 | 0.8381     | 0.8401 |

El modelo de **LightGBM** proporciona una precisión del 84,01%, lo que significa que de cada 100 reservas que se predicen que van a ser canceladas, 84 cancelan realmente.

# IDENTIFICACIÓN DE LOS FACTORES CLAVE DEL COMPORTAMIENTO DEL CLIENTE



- **Antelación (lead time): El factor más crítico.**  
Las reservas hechas con meses de antelación concentran el mayor volumen de cancelaciones.
- **Vínculo del cliente con el hotel (Special Requests):**  
Los clientes que personalizan mucho su estancia aseguran su presencia. La falta de peticiones especiales (cero interacciones con el hotel) es un riesgo claro de cancelación.
- **Sensibilidad al precio:**  
A mayor precio por habitación, el algoritmo detecta un incremento directo en la probabilidad de abandono.
- **Otros factores de riesgo:**  
Mes de llegada y tipo de canal por el que se realiza la reserva.



# CREACIÓN DE PERFILES FIABLE VS RIESGO PARA LA TOMA DE MEJORES DECISIONES



SEGMENTO CRÍTICO

## Cliente de riesgo



**Antelación:** Extrema (>150 días).



**Interacción:** Cero peticiones especiales. Nulo compromiso con el hotel.



**Precio habitación:** Alto (>120€).



**Canal:** Reserva 100% Online.



**Logística:** Sin plaza de parking solicitada.



**Historial:** Cliente nuevo.



SEGMENTO FIDELIZADO

## Cliente fiable



**Antelación:** Corta (<40 días).



**Interacción:** Alta personalización (2+ peticiones especiales).



**Precio habitación:** Bajo (<90€).



**Canal:** Reserva Offline.



**Logística:** Reserva plaza de parking.



**Historial:** Huésped repetidor.

# DESPLAZAMIENTO DEL UMBRAL PARA AUMENTAR LA PRECISIÓN

89.47%

Precisión con el threshold en 0.7

## Moviendo el threshold a 0.7

Hemos decidido ser más exigentes con el modelo. En lugar de actuar con el threshold estándar, ahora solo marcamos una reserva como "cancelación" si el modelo tiene un **70% de certeza**.

- ✓ Casi 9 de cada 10 alertas de cancelación son aciertos reales.
- 🛡️ Reducimos drásticamente los Falsos Positivos, protegiendo al hotel de falta de habitaciones.

# LOS BENEFICIOS DEL HOTEL PUEDEN ASCENDER HASTA EN UN 35.8%

**24%**  
Overbooking Total  
Sugerido

**+35.8 %**  
Incremento del beneficio

## Composición de la Estrategia

**14% Fiable:** Basado en el umbral de máxima seguridad (0.7).

**+ 10% Estratégico:** El 20% de las reservas que nuestro modelo predice que van a salir adelante acaban siendo canceladas.

---

Esta cifra es el **punto de equilibrio** donde maximizamos los beneficios sin dejar a ningún cliente sin habitación.

Nos asegura una **ocupación alrededor del 90%**.

# CONCLUSIONES

---

Hemos desarrollado un **modelo capaz de adaptarse** al comportamiento real del cliente.

---

**Creamos perfiles fiables y de riesgo**, para hacer estrategias de atracción.

---

Ajustamos el umbral de decisión al 70% para **minimizar los falsos positivos**, priorizando en todo momento la reputación y el servicio del hotel.

---

**Estrategias de overbooking:** Compensamos esta precaución utilizando nuestra estimación de falsos negativos. Esto nos permite calcular estadísticamente cuántas habitaciones extra podemos vender de forma segura para maximizar la ocupación.

# PRÓXIMOS PASOS



Incluir nuevas variables de estudio para poder predecir mejor la tasa de cancelación de los clientes.



Recoger más datos para poder ver diferentes tendencias según épocas del año y poder afinar más el overbooking.



Incluir un chatbot para automatizar la detección de clientes propensos a cancelar y que genere el overbooking óptimo.



Propuestas de campañas de marketing concretas, basadas en las características particulares de cada individuo.

# Preguntas y sugerencias

Gracias por su atención